

BTK Datathon 2026

Kariyer Başarı Skoru Tahmini

Uçtan Uca Makine Öğrenmesi ve NLP Proje Dokümantasyonu

Problem Türü	Regresyon (0-100 arası sürekli hedef değişken)
Değerlendirme Metriği	Ortalama Kare Hata (MSE)
Veri Seti	10.000 train / 10.000 test satırı, 46 özellik
En İyi Kaggle Public Skoru	90.33 (V5 Stacking Ensemble)
Kullanılan Modeller	XGBoost, LightGBM, CatBoost, Stacking
Araçlar	Google Colab, Python, scikit-learn, Optuna

Hazırlayan: Serdar Arıcı

GitHub: github.com/serdararici/btk-datathon-2026

Kaggle: kaggle.com/serdararici

Haziran 2026

Özet

Bu bölüm, dokümanın tamamını okumak istemeyenler için projenin tüm akışını kısaca özetler. Detaylar ve gerekçeler ilgili bölümlerde bulunabilir.

Problem ve Veri

Hedef, öğrenci verilerinden (akademik, teknik, proje, portfolyo, mülakat, sosyal beceri ve mentor geri bildirim metni) yola çıkarak 0-100 arasında sürekli bir `career_success_score` değerini tahmin etmektir. Değerlendirme metriği MSE (Ortalama Kare Hata) idi, düşük skor daha iyi.

Uygulanan Adımlar

- EDA — eksik değerler, hedef dağılımı, korelasyonlar incelendi; hobby ve sosyal medya platformu gibi sinyal taşımayan "gürültü" sütunları tespit edilip atıldı.
- Ön işleme — eksik değerler mantığa dayalı şekilde dolduruldu (örn. staj yoksa süre 0); `university_tier` sıralı olduğu için Label Encoding, `department/target_role` için One-Hot Encoding kullanıldı.
- Feature engineering — beceri ortalamaları, deneyim skoru, role göre ağırlıklandırılmış skor, etkileşim özellikleri (örn. `cgpa` × proje kalitesi) ve log dönüşümleri türetildi.
- NLP — `mentor_feedback_text` alanından Türkçe sentiment kelime sayımı ve TF-IDF ile özellikler çıkarıldı; `sentiment_score` hedefle 0.40 korelasyona ulaştı.
- Modelleme — XGBoost, LightGBM, CatBoost modelleri Optuna ile ayarlandı; bu üç modelin OOF tahminleri bir Ridge meta-modeliyle birleştirilen stacking ensemble kuruldu.
- İleri analiz — modelin neden daha fazla iyileşmediğini anlamak için gürültü analizi, adversarial validation ve birkaç hipotez testi (örnek ağırlıklandırma, yıl sütunlarını çıkarma) yapıldı; bazıları doğrulandı, bazıları kanıta dayalı olarak elendi.

Sonuç

Kaggle public MSE skoru, beş versiyon boyunca 99.09'dan 90.33'e düşürüldü. En iyi model, tuned XGBoost + LightGBM + CatBoost'u Ridge meta-model ile birleştiren stacking ensemble'dır. Proje boyunca en büyük tekil iyileştirme hiperparametre tuning'den geldi (~6 puan); NLP de belirgin katkı sağladı.

1. Projeye Genel Bakış

Bu proje, Google ve Girişimcilik Vakfı iş birliğiyle BTK Akademi tarafından düzenlenen Datathon 2026 yarışması için geliştirilmiştir. Amaç, öğrencilerin akademik, teknik, proje, portfolyo, mülakat ve sosyal profil verilerinden yola çıkarak `career_success_score` (kariyer başarı skoru) adı verilen, 0 ile 100 arasında sürekli bir hedef değişkeni tahmin etmektir.


Veri seti üç farklı veri türünü tek bir problemde birleştiriyor: sayısal özellikler (beceri skorları, sayılar), kategorik özellikler (bölüm, hedef rol, üniversite seviyesi) ve bir doğal dil alanı (`mentor_feedback_text`) — mentor tarafından yazılmış kısa Türkçe değerlendirme metni. Yarışmanın önemli bir gereksinimi, sadece klasik sayısal değişkenlerden değil, bu serbest metin alanından da NLP teknikleriyle bilgi çıkarmaktır.

Yarışma Ortalama Kare Hata (MSE) ile değerlendirilir: düşük değer daha iyi anlamına gelir. MSE her hatayı kareye aldığı için büyük hatalar küçük hatalardan çok daha ağır cezalandırılır, bu da modeli tutarlı ve dengeli tahminlere yönlendirir.

1.1 Metodoloji — Aşamalı (İteratif) Geliştirme

Tek seferde büyük bir model kurmak yerine proje, aşamalı ve ölçülebilir bir yaklaşım izledi. Her versiyon (V1-V5) öncekinin üzerine tek bir büyük fikir ekledi ve her versiyon Kaggle'a gönderilerek her değişikliğin gerçek etkisi gözlemlendi. Bu yaklaşım profesyonel veri bilimi iş akışlarını yansıtır ve hangi fikirlerin işe yaradığını, hangilerinin yaramadığını kesin olarak görmemizi sağladı.

Versiyon	Eklenen Geliştirme	Kaggle MSE
V1	Baseline XGBoost (feature engineering yok)	99.09
V2	Feature engineering (toplamlar, oranlar)	98.83
V3	NLP özellikleri (sentiment + TF-IDF)	97.33
V4	Ensemble (XGB+LGB+Cat) + Optuna tuning	91.26
V5	Stacking + etkileşimler + log dönüşümleri	90.33




Şekil 1: MSE, beş iterasyon boyunca 99.09'dan 90.33'e düzenli şekilde düştü.

2. Keşifsel Veri Analizi (EDA)

Her veri bilimi projesi EDA ile başlar — modellemeden önce veriyi anlamak. EDA şu sorulara cevap verir: veri nasıl şekillenmiş, eksik değerler nerede, hedef değişken nasıl dağılmış ve hangi özellikler hedefle ilişkili. Buradaki bulgular sonraki tüm kararları şekillendirdi.

2.1 Eksik Değerler


Yedi sütunda eksik değer bulundu. En kötüsü `internship_duration_months` idi (~%16.57 eksik). Bunu incelemek önemli bir patern ortaya çıkardı: eksik süreye sahip satırların %82'si sıfır staj yapmış öğrencilere aitti. Bu, değerinde "eksik" olmadığı, mantıksal olarak 0 olması gerektiği anlamına geliyordu. Bu bulgu, kör medyan doldurma yerine akıllı bir doldurma stratejisi geliştirmemizi sağladı.



Şekil 2: Sütunlara göre eksik değerler. En çok eksik `internship_duration_months`'ta.

2.2 Hedef Değişken Dağılımı


Hedef değişkenin (`career_success_score`) ortalaması 76.9, standart sapması 15.2 ve aralığı 0–100. Dağılım hafif sola çarpık (çarpıklık -0.45): öğrencilerin çoğu 67–88 aralığında skor alırken, düşük skorlara doğru daha uzun bir kuyruk var. Bu bize "sadece ortalamayı tahmin et" şeklinde basit bir modelin RMSE değerinin ~15 civarında olacağını gösterdi — bunu geçmemiz gereken net bir başlangıç noktası oldu.



Şekil 3: Hedef değişken 77 civarında yoğunlaşmış; 773 öğrenci tam 100 puan almış (tavan etkisi).

2.3 Özellik Korelasyonları


Korelasyon analizi hangi özelliklerin sinyal taşıdığını ortaya koydu. `project_quality_score` açık farkla en güçlüsüydü (0.54), ardından `technical_interview_score` (0.34) ve bir grup teknik beceri (0.25–0.29) geliyordu. Çarpıcı bir bulgu: `cgpa`'nın hedefle korelasyonu neredeyse sıfırdı (–0.01) — akademik not ortalaması tek başına kariyer başarısını öngörmüyor. Bu sezgiye aykırı sonuç, ileride yapılan ileri analizde önemli bir rol oynadı.



Şekil 4: `project_quality_score` baskın; `cgpa` ve yıl özellikleri tek başına neredeyse sıfır.

2.4 Kategorik Özellikler — Gürültü Tespiti

Kritik bir EDA adımı, kategorik sütunların gerçekten önemli olup olmadığını kontrol etmektir. Her kategori için ortalama hedef skorunu çizdirince, hobby ve preferred_social_media_platform sütunlarının kategoriler arasında neredeyse hiç fark göstermediği görüldü — tüm barlar ~77 civarındaydı. Bunlar etkin olarak gürültü sütunları (yarışma verisine kasıtlı olarak eklenmiş tuzaklar olabilir). Bunları tespit edip atmak, tüm sütunları körü körüne modele veren diğer yarışmacılara karşı ince bir avantaj sağladı.



Şekil 5: department, hobby ve platform düz ortalamalar gösteriyor (gürültü); target_role ve university_tier hafif bir yapı gösteriyor.

3. Veri Ön İşleme (Preprocessing)

Ön işleme, ham veriyi modelleme için hazırlar. Bu aşamada iki ilke yol gösterdi: data leakage'dan kaçınmak (test bilgisinin asla eğitimi etkilememesi) ve alana özgü akıllı doldurma (eksikleri kör kör değil, mantıklı şekilde doldurmak).

3.1 Akıllı Eksik Değer Doldurma

internship_duration_months için mantığı ikiye ayırdık: sıfır staj yapan öğrencilere 0, staj yapmış ama süresi eksik olanlara ise train medyanı (8.0) verildi. Diğer tüm sayısal eksikler (english_exam_score, github_avg_stars vb.) sadece train medyanı ile dolduruldu — aynı medyanlar test setine de uygulandı. İstatistikleri sadece train'den hesaplamak data leakage'ı önleyen temel kuraldır.

3.2 Kategorik Değişken Kodlama (Encoding)

Kategorinin sıralı olup olmamasına göre iki strateji seçildi:

- Label Encoding: university_tier için — sıralı bir yapı var (Tier 1 > Tier 2 > ...), 4,3,2,1 olarak eşlendi.
- One-Hot Encoding: department ve target_role için — sırasız kategoriler, her biri 0/1 sütununa dönüştürüldü.

Burada ufak ama önemli bir hata yakalandı ve düzeltildi: sütun hizalama (align) işlemi sırasında hedef sütun, yanlışlıkla sıfırlarla doldurularak test setine kopyalanıyordu. Hedefi encoding'den önce ayırmak bu sorunu çözdü — dikkatli doğrulamanın neden önemli olduğunu gösteren iyi bir örnek.


3.3 Atılan Sütunlar

EDA bulgularına göre gürültü sütunları (hobby, preferred_social_media_platform), kimlik sütunu (student_id — sadece final submission dosyası için ayrı tutuldu) ve ham metin alanı (mentor_feedback_text — çıkarılan NLP özellikleriyle değiştirildi) model girdisinden çıkarıldı.


4. Feature Engineering (Özellik Mühendisliği)

Ham veriden yeni ve daha anlamlı sütunlar türetmek olan feature engineering, çoğu zaman bir yarışmadaki en değerli aşamadır. Aşağıdaki özellikler oluşturuldu:

- `avg_technical_score` — 9 teknik beceri skorunun ortalaması. Önem sıralamasında 2. sıraya yerleşti.
- `avg_soft_skill_score` — iletişim, takım çalışması, liderlik, sunum ortalaması.
- `experience_score` — staj, gerçek müşteri projesi, freelance ve hackathon'ların ağırlıklı bileşimi.
- `role_weighted_score` — öğrencinin hedef rolüne göre ağırlıklandırılmış teknik beceriler (örn. Data Scientist için ML daha ağırlıklı).
- Etkileşim özellikleri — `technical_interview` × `problem_solving` gibi çarpımlar, "güçlü VE gösterilebilir" profilleri yakalamak için.
- `cgpa` etkileşimleri — `cgpa` × `project_quality` gibi, `cgpa`'nın gizli/kontrollü önemini ortaya çıkarmak için.
- Log dönüşümleri — `github_avg_stars` gibi sağa çarpık sayım özelliklerine `log1p` uygulandı (korelasyonu 0.15'ten 0.18'e çıkardı).



Şekil 6: V2'de türetilen 8 yeni özelliğin hedefle korelasyonu — `avg_technical_score` ve `role_weighted_score` en güçlüsü.



Şekil 7: XGBoost modelinde en önemli 20 özellik — `avg_technical_score`, ham sütunlar arasında 2. sıraya yerleşti.

Türetilen her özellik eşit derecede faydalı olmadı. `interview_success_rate` ve `hackathon_efficiency` neredeyse sıfır korelasyon gösterdi ve az katkı sağladı — "daha fazla özellik otomatik olarak daha iyidir" yanılgısına karşı bir hatırlatma. Ağaç tabanlı modeller birçok etkileşimi zaten kendiliğinden yakalayabildiğinden, elle yapılan etkileşimler burada sadece sınırlı bir kazanç sağladı.


5. Doğal Dil İşleme (NLP)

`mentor_feedback_text` alanı, mentor tarafından yazılmış kısa bir Türkçe değerlendirmedir. Örnekleri okumak net bir patern ortaya çıkardı: yüksek skorlu öğrenciler "dikkat çekici", "güçlü", "potansiyeli büyük" gibi kelimeler alırken, düşük skorlular "ancak", "çalışması gerekiyor", "gelişmekte" gibi ifadeler alıyordu. Üç katmanlı bir NLP stratejisi kuruldu:

- Duygu (sentiment) kelime sayımı — elle oluşturulmuş Türkçe pozitif / negatif / potansiyel kelime listeleri, metin başına sayıldı.
- Sentiment skoru ve oranı — pozitif eksi negatif, ve pozitifin toplam içindeki payı.
- TF-IDF — en ayırt edici 100 kelime/kelime grubu otomatik olarak seçildi (Türkçe stopwords temizliği ve Türkçe'ye özel küçük harfe çevirme ile).

Sonuçlar yaklaşımı doğruladı. `sentiment_score`, hedefle 0.40 korelasyona ulaştı — tüm veri setinde `project_quality_score`'dan sonra ikinci en güçlü sinyal. TF-IDF, elle oluşturulan

listeleri bağımsız olarak doğruladı: "ancak" kelimesi en güçlü negatif sinyaldi (-0.24), çünkü Türkçe'de genellikle bir övgüden sonra eleştiri getirir. İlginç bir nüans: "potansiyel" kelimeleri negatif korelasyon gösterdi — mentorlar bu kelimeleri henüz başarılı olmayan ama umut veren öğrenciler için kullanıyor.



Şekil 8: *sentiment_score* ve *sentiment_ratio* en güçlü NLP sinyalleri; *negatif* kelimeler *negatif* korelasyon gösteriyor.

6. Modelleme ve Ensemble

6.1 Neden Gradient Boosting

Bu tür tablo verisi için gradient boosting modelleri kanıtlanmış en güçlü yöntemdir. Üç model kullanıldı: XGBoost, LightGBM ve CatBoost. Her biri, önceki ağaçların hatalarını düzeltmeye çalışan sıralı bir karar ağacı dizisi kurar. İç mekanikleri farklılaşır — CatBoost özellikle kategorik yapıyı çok iyi işler, bu yüzden burada sürekli en güçlü tekil model oldu.

6.2 Optuna ile Hiperparametre Optimizasyonu

Varsayılan model ayarları nadiren en uygundur. Optuna, çapraz doğrulanmış MSE'yi hedef alarak en iyi hiperparametreleri (ağaç sayısı, öğrenme hızı, derinlik, örnekleme oranları) otomatik olarak aramak için kullanıldı. Tuning, projenin tek başına en büyük iyileştirmesini sağladı — Kaggle skorunda yaklaşık 6 puanlık bir düşüş ($97.33 \rightarrow 91.26$) — bu da doğru ayarların herhangi bir tekil özellikten daha fazla önem taşıdığını doğruladı.

6.3 Stacking Ensemble ve Meta-Model Seçimi

Basit bir ortalama yerine, final model stacking kullandı. Her temel model, hiç eğitilmediği veri üzerindeki tahminler olan out-of-fold (OOF) tahminler üretti; bunlar daha sonra bir "meta-model"e girdi olarak verildi. OOF tekniği leakage'ı önlemek için gereklidir: temel modeller eğitildikten sonra aynı satırları tahmin etmeleri istenseydi, o satırları "ezberler" ve meta-modeli yanıltırlardı.

Meta-model olarak Ridge Regresyon seçildi. Üç temel model (XGBoost, LightGBM, CatBoost) birbirine çok benzer tahminler ürettiği için, meta-modelin görevi karmaşık yeni ilişkiler öğrenmek değil, üç tahmini dengeli bir şekilde birleştirmektir — bu da basit ve sağlam bir modelin (Ridge) karmaşık bir modelden (örneğin başka bir XGBoost) daha uygun olduğu bir durumdur. Ridge, sıradan Linear Regression'dan farklı olarak L2 regularization içerir; bu, birbirine çok benzeyen girdiler (üç model tahmini) arasında ağırlıkların aşırı uçlara kaymasını önleyerek daha dengeli ve genellenebilir bir birleşim sağlar.

Ridge, sabit ağırlıklar kullanmak yerine her temel modele ne kadar güvenileceğini veriden öğrendi: $\text{final_tahmin} = 0.35 \times \text{XGBoost} + 0.08 \times \text{LightGBM} + 0.60 \times \text{CatBoost} - 1.98$. En yüksek ağırlık, en düşük OOF hatasına sahip CatBoost'a verildi; LightGBM'in ağırlığı ise neredeyse sıfıra yakındı çünkü performansı diğer ikisinin gerisinde kalmıştı. Stacking, hem basit ortalamaı hem de en iyi tekil modeli geride bıraktı.

7. İleri Analiz ve Hipotez Testleri

V5 sonrası skor ~90 seviyesinde sabitlenince, nedenini anlamak için daha derin bir teşhis aşaması yürütüldü. Birden fazla hipotez test edildi — bazıları doğrulandı, bazıları reddedildi. Her iki türden sonucu da dürüstçe belgelemek, sağlam veri biliminin bir parçasıdır.

- Gürültü analizi — Lineer bir model ~ 9.9 standart sapmalı bir kalıntı (residual) bıraktı ($R^2 \sim 0.57$), bu da hedef değışkende anlamlı miktarda indirgenemeyen gürültü olduğunu gösterdi. Yapılan bir deneyde çapraz doğrulama MSE'si ~ 82 olarak ölçüldü; ancak bu kesin bir matematiksel alt sınır değildi — ilerleyen adımlarda daha fazla feature engineering ve daha kapsamlı tuning ile bu değerin altına (~ 79 'a) inilebildi. Veri sentetik üretildiği için gerçek gürültü oranı yalnızca veriyi üreten taraf tarafından bilinebilir; bizim rakamlarımız sadece o ana kadar ulaşılan en iyi tahminlerdir.
- cgpa paradoksu — cgpa tek başına ~ 0 korelasyona sahip, ama diğer özellikler kontrol edildiğinde yüksek bir katsayı alıyor. Etkisi etkileşimlerde gizli; bu bulgu cgpa etkileşim özelliklerinin eklenmesine yol açtı.
- Adversarial validation — Bir sınıflandırıcı train ile test'i ayırt edebildi (AUC 0.66), bunun başlıca sebebi application_year ve graduation_year idi: test seti daha yakın yıllardan geliyor.
- Örnek ağırlıklandırma denemesi — Train satırlarını test'e benzerliklerine göre ağırlıklandırmak denendi, ancak çapraz doğrulamayı kötüleştirdi ($83.1 \rightarrow 84.5$) ve bu yöntem kullanılmadı.
- Yıl sütunlarını çıkarma denemesi — Dağılım kaymasıyla başa çıkmak için yıl sütunları çıkarılıp Kaggle'da test edildi, ancak skor kötüleşti ($90.3 \rightarrow 100.5$). Sonuç: kayma olmasına rağmen yıl özellikleri gerçekten faydalı, bu yüzden korundu.

Toplanan kanıtlar, modelin veride mevcut olan gerçek sinyale yakın bir performansa ulaştığını gösteriyor. Çapraz doğrulama (~ 79) ile Kaggle (~ 90) arasındaki kalan fark, modelleme hatasından değil, public test alt kümesinin doğal zorluğundan ve yıl dağılımı kaymasından kaynaklanıyor; bu farkın tamamen kapatılıp kapatılamayacağı, yarışma süresi içinde kesin olarak test edilememiştir.

8. Sonular ve Deęerlendirme

Proje, Kaggle public MSE skorunu 99.09'dan 90.33'e dūřurdū — disiplinli ve llebilir iterasyon yoluyla 8.76 puanlık bir iyileřtirme. En iyi model; ayarlanmıř XGBoost, LightGBM ve CatBoost'u birleřtiren, 122'den fazla tūretilmiř sayısal ve NLP zellięi kullanan bir stacking ensemble'dir.

Ařama	Temel Katkı	Etki
EDA	Gūrūltū sūtunlarının ve akıllı doldurma hedeflerinin belirlenmesi	Temel
Feature Eng.	Toplamlar, oranlar, etkileřimler	Orta
NLP	Sentiment (0.40 korelasyon) + TF-IDF	Gūlū
Tuning (Optuna)	Optimal hiperparametreler	En būyūk (~6 puan)
Stacking	Dinamik model birleřtirme	İnce ayar

8.1 Temel ıkarımlar

- Hiperparametre tuning en būyūk tekil kazancı saęladı — doęru ayarlar bazen zelliklerden daha nemli olabiliyor.
- NLP gerekten deęer kattı; Tūrke "ancak" kelimesi metin tabanlı en gūlū negatif sinyaldi.
- Her fikir iře yaramadı — rnek aęırlıklandırma ve yıl sūtunlarını ıkarma denenip kanıta dayalı olarak elendi.
- Veri setinde anlamlı miktarda indirgenemeyen gūrūltū var; bu gereęi fark etmek beklentileri gereki tutmaya yardımcı oldu, ancak kesin bir alt sınır kanıtlanamadı.
- Her deęiřiklięi apraz doęrulama ve Kaggle ile lmek, sūreci dūrūst ve tekrarlanabilir tuttu.

8.2 Aralar ve Tekrarlanabilirlik

Tūm alıřma Google Colab ūzerinde yapıldı (cretsiz GPU, sıfır kurulum, yerleřik GitHub entegrasyonu). Proje, versiyonlanmıř notebook'lara (v1_baseline'dan v5_advanced'a kadar) ayrılmıřtır; tūm veriler, ıktılar ve grafikler versiyon kontrolūndedir. Her notebook GitHub'a kaydedilirken kendi Colab ama linkini ierecek řekilde eklenmiřtir, bu sayede her notebook tek bařına alıřtırılabilir ve doęrudan Colab'da aılabilir durumdadır.

Kaynak	Baęlantı
GitHub Deposu (tūm notebook'lar)	github.com/serdararici/btk-datathon-2026
Kaggle Profili	kaggle.com/serdararici

Çalışma Ortamı	Google Colab (her notebook içinde gömülü Colab linki mevcuttur)
----------------	---